

15. Vorlesung: Einführung in der Statistik

Nikolas Tapia

10. Juni 2024, Stochastik für Informatik(er)

15. Vorlesung: Einführung in der Statistik

Nikolas Tapia

10. Juni 2024, Stochastik für Informatik(er)

Wahrscheinlichkeitstheorie

- Theoretische Grundlagen $\Rightarrow ZV$
- Modellierung von Zufallsprozessen $(X_1, \dots, X_n) \in \mathbb{R}^n$
- Axiomatische Definitionen

Statistik

- Analyse und Interpretation von Daten
- Aufstellung von Modellen \downarrow
- Fragen: $(x_1, \dots, x_n) \in \mathbb{R}^n$
 - Bestimmung von Kenngrößen
 - Schätzung von Parametern
 - Hypothesentests

Hypothese

1. Die gemessenen Daten sind einzelne *Realisierungen* von unabhängigen, identisch verteilten Zufallsvariablen. $(X_1, \dots, X_n) \text{ u.i.v. } ZV \Rightarrow (x_1, \dots, x_n) \in \mathbb{R}^n$
2. Die gemessenen Daten stellen eine *Stichprobe* aus einer *Population* dar.

Definition 15.1

Sei $(x_1, \dots, x_n) \in \mathbb{R}^n$ ein Vektor von Messwerten. Sei $x \in \mathbb{R}$. Die **absolute Häufigkeit** von x ist

$$H(x) := |\{i : x_i = x\}|.$$

Die **relative Häufigkeit** von x ist

$$h(x) := \frac{H(x)}{n}.$$

Definition 15.2

Sei $(x_1, \dots, x_n) \in \mathbb{R}^n$ ein Vektor von Messwerten. Eine **Klasseneinteilung** ist eine Zusammenfassung der Messwerte zu disjunkte Mengen $A_1, \dots, A_m \subseteq \mathbb{R}$ mit $m \leq n$, sodass jedes x_i zu genau einem A_j gehört.

Die **absolute Häufigkeit** einer Klasse A ist

$$H(A) := |\{i : x_i \in A\}|.$$

Die **relative Häufigkeit** einer Klasse A ist

$$h(A) := \frac{H(A)}{n}.$$



↘ Dauer in Sekunden, gerundet auf eine Kommastelle.

(10,9; 6,8; 8,9; 5,6; 9,8; 2,3; 4,6; 2,8; 6,5; 3,10,7,8,0; 1,8; 8,9; 10,7)

$$H(10,9) = 1, H(10,7) = 2, H(4,0) = 0$$

$$h(10,9) = \frac{1}{14}, h(10,7) = \frac{2}{7}, h(4,0) = 0$$

Definition 15.3

Sei $(x_1, \dots, x_n) \in \mathbb{R}^n$ ein Vektor von Messwerten. Das **empirische Mittel** von (x_1, \dots, x_n) ist definiert als

$$\bar{\mu}_n(x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n x_i.$$

Definition 15.4

Sei $(x_1, \dots, x_n) \in \mathbb{R}^n$ ein Vektor von Messwerten. Die **empirische Varianz** von (x_1, \dots, x_n) ist definiert als

$$\bar{\sigma}_n^2(x_1, \dots, x_n) := \boxed{\frac{1}{n-1}} \sum_{i=1}^n (x_i - \bar{\mu}_n(x_1, \dots, x_n))^2.$$


statt $\frac{1}{n}$!

Die **empirische Standardabweichung** von (x_1, \dots, x_n) ist $\bar{\sigma}_n := \sqrt{\bar{\sigma}_n^2}$.

Definition 15.5

Sei $(x_1, \dots, x_n) \in \mathbb{R}^n$ ein Vektor von Messwerten. Die **empirische Median** von (x_1, \dots, x_n) ist definiert als der Wert in der Mitte der geordneten Liste. Falls n gerade ist, ist der Median der Durchschnitt der beiden mittleren Werte.

Ausreißer



$x = (10,9; 6,8; 8,9; 5,6; 9,8; 2,3; 4,6; 2,8; 6,5; 3,10,7,8,0; 1,8; 8,9; 10,7)$

$\bar{\mu}_n(x) = 8,014$ empirisches Mittel

$\bar{\sigma}_n^2(x) = 4,677$ empirische Varianz.

median:

$(2,3; 2,8, \dots) \Rightarrow \frac{8,1 + 8,2}{2} = 8,15 = \text{median.}$
 $\approx \bar{\mu}_n$

Definition 15.6

Seien X_1, \dots, X_n Zufallsvariablen. Eine **Schätzfunktion** zur Stichprobengröße n ist eine Funktion $\theta_n: \mathbb{R}^n \rightarrow \mathbb{R}$, welche die Zufallsvariablen X_1, \dots, X_n auf $\theta_n(X_1, \dots, X_n)$ abbildet.

Bem: $\theta_n(X_1, \dots, X_n)$ ist eine ZV.

$\bar{\theta}_n := \theta_n(x_1, \dots, x_n) \in \mathbb{R} \Rightarrow$ Schätzer für θ
Parameter
der Verteilung der X_i .

Realisierung

$$\bar{\mu}_n(x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n x_i \quad \left((x_1, \dots, x_n) \stackrel{\phi}{=} (X_1, \dots, X_n) \right)$$

$$\bar{\mu}_n(X_1, \dots, X_n) \tilde{\sim} \mu \quad \text{falls} \quad \mathbb{E}[X_1] = \dots = \mathbb{E}[X_n] = \mu.$$

Satz der Großen Zahlen:

$$\bar{\mu}_n(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \mathbb{E}[X_1] = \mu$$

$$\mathbb{E}[\bar{\mu}_n(X_1, \dots, X_n)] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot n\mu = \mu.$$

$$V(X) = \mathbb{E}[(X - \mathbb{E}(X))^2]$$

$$\begin{aligned}
 \mathbb{E}[\bar{\sigma}_n(X_1, \dots, X_n)] &= \mathbb{E}\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{\mu}_n(X_1, \dots, X_n))^2\right] \\
 &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}[(X_i - \bar{\mu}_n)^2] \\
 &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}[X_i^2 - 2\bar{\mu}_n X_i + \bar{\mu}_n^2] \\
 &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}[X_i^2] - \frac{2}{n-1} \sum_{i=1}^n \mathbb{E}[\bar{\mu}_n X_i] + \frac{n}{n-1} \mathbb{E}[\bar{\mu}_n^2] \\
 &\quad \mu^2 + \sigma^2
 \end{aligned}$$

$$(a+b)^2 = a^2 + b^2 + 2ab$$

$$\begin{aligned}\mathbb{E}[\bar{\mu}_n^2] &= \frac{1}{n^2} \mathbb{E}\left[\left(\sum_{i=1}^n X_i\right)^2\right] = \frac{1}{n^2} \mathbb{E}\left[\sum_{i=1}^n X_i^2 + 2 \sum_{i < j} X_i X_j\right] \\ &= \frac{1}{n^2} \left(n(\mu^2 + \sigma^2) + 2 \sum_{i < j} \mathbb{E}[X_i X_j] \right) \\ &= \frac{1}{n} \mu^2 + \frac{1}{n} \sigma^2\end{aligned}$$

$$\Rightarrow \mathbb{E}[\bar{\sigma}_n^2(X_1, \dots, X_n)] = V(X_1) = \sigma^2$$



Eigenschaften von Schätzern

Sei $(x_1, \dots, x_n) \in \mathbb{R}^n$ ein Vektor von Messwerten, welche als Realisierungen von identisch verteilten Zufallsvariablen (X_1, \dots, X_n) mit Parameter θ gelten.

Sei $\theta_n: \mathbb{R}^n \rightarrow \mathbb{R}$ eine Schätzfunktion zur Stichprobengröße n .

Definition 15.7

Der Schätzer θ_n heißt **erwartungstreu** für θ , falls

$$\underbrace{\mathbb{E}[\theta_n(X_1, \dots, X_n)]}_{\text{Schätzfunktion}} = \theta. \Rightarrow \theta_n(x_1, \dots, x_n) \approx \theta$$

↖ Parameter.

Definition 15.8

Der Schätzer θ_n heißt **konsistent**, falls

$$\lim_{n \rightarrow \infty} \theta_n(x_1, \dots, x_n) = \theta.$$

Definition 15.9

Der Schätzer θ_n heißt **effizient** falls

$$\lim_{n \rightarrow \infty} \mathbb{V}[\theta_n(X_1, \dots, X_n)] = 0.$$

$\theta_n(x_1, \dots, x_n) \approx \text{kst.}$
für große n .

Erwartungswert $E[X_1] = \mu$.

$$E[\bar{\mu}_n(X_1, \dots, X_n)] = \mu \Rightarrow \bar{\mu}_n \text{ erwartungstreu}$$

Satz der
großen Zahlen $\rightarrow \Rightarrow \bar{\mu}_n$ konsistent.

$\bar{\mu}_n$ ist auch effizient.

$$E[\bar{\sigma}_n^2(X_1, \dots, X_n)] = \sigma^2 \Rightarrow \bar{\sigma}_n^2 \text{ erwartungstreu}$$

$$= V(X_1) \Rightarrow \bar{\sigma}_n^2 \text{ konsistent.}$$

$$\tilde{\sigma}_n^2(x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mu}_n(x_1, \dots, x_n))^2$$

$\tilde{\sigma}_n^2$ ist konsistent, aber nicht erwartungstreu.